



计算机工程与应用
Computer Engineering and Applications
ISSN 1002-8331, CN 11-2127/TP

《计算机工程与应用》网络首发论文

题目: 表面肌电手部动作识别的研究进展
作者: 李振江, 魏德健, 冯妍妍, 于丰帆, 马一凡
网络首发日期: 2023-08-14
引用格式: 李振江, 魏德健, 冯妍妍, 于丰帆, 马一凡. 表面肌电手部动作识别的研究进展[J/OL]. 计算机工程与应用.
<https://link.cnki.net/urlid/11.2127.TP.20230811.1647.016>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

表面肌电手部动作识别的研究进展

李振江, 魏德健, 冯妍妍, 于丰帆, 马一凡

山东中医药大学 智能信息与工程学院, 济南 250355

摘 要:表面肌电信号 (Surface electromyography, sEMG) 是一种测量肌肉活动的非侵入式方法, 蕴含着关联人体运动的丰富信息, 可用于手部动作识别。基于 sEMG 手部动作识别是指通过分析手部肌肉的 sEMG 信号, 实现对手部动作的分类和识别。在神经网络发展的推动下, sEMG 在手部动作识别领域取得了显著进展。但 sEMG 面临着噪声大、稳定性差等缺陷, 难以有效利用, 给高精度手部动作识别模型的获取带来了巨大困难, 阻碍了研究成果的转化应用。本文详细归纳了 sEMG 手部动作识别方法的研究进展。首先介绍了常用于动作识别领域的公开肌电数据集, 并介绍了自测肌电数据集采集流程; 然后根据研究方法不同将现有的 sEMG 手部动作识别模型分为基于机器学习的手部动作识别、基于深度学习的手部动作识别和基于混合网络结构的手部动作识别三类, 分别对相关模型进行总结分析, 对不足之处提出建议; 最后对手部动作识别研究需要解决的问题和未来发展方向进行了展望。

关键词: sEMG; 手部动作识别; 人工神经网络; 算法模型

文献标志码: A **中图分类号:** TP391.4 doi: 10.3778/j.issn.1002-8331.2305-0269

Research progress of surface electromyography hand motion recognition

LI Zhenjiang, WEI Dejian, FENG Yanyan, YU Fengfan, MA Yifan

College of Intelligence and Information Engineering, Shandong University of Traditional Chinese Medicine, Jinan 250355, China

Abstract: Surface electromyography (sEMG) is a non-invasive method of measuring muscle activity, which contains rich information related to human motion and can be used for hand motion recognition. Hand motion recognition based on sEMG refers to the classification and recognition of hand motions by analyzing the sEMG signals of the hand muscles. Driven by the development of neural networks, sEMG has made great progress in the field of hand motion recognition. However, sEMG is faced with defects such as high noise and poor stability, which cannot be efficiently utilised, bringing great difficulties in acquiring high-precision hand movement recognition models and has hindered the translation and application of research results. This paper summarizes the research progress of sEMG hand motion recognition methods in detail. Firstly, public EMG datasets commonly used in the field of action recognition are introduced, and the self-test EMG set acquisition process is described; then the existing sEMG hand motion recognition models are classified into three categories according to the different research methods: hand motion recognition based on machine learning, hand motion recognition based on deep learning and hand motion recognition based on hybrid network structure, and the related models are summarised and analysed respectively, and suggestions are made for the shortcomings; finally, the problems to be solved and the future development direction of hand action recognition research are prospected.

Key words: sEMG; hand motion recognition ;artificial neural networks; algorithm model

基金项目: 国家自然科学基金面上项目(82074579, 82174528);教育部产学研合作协同育人项目(202101008007);山东省中医药科技项目(2020M006);山东省研究生教育质量提升计划项目(SDYKC21055);山东省本科教学改革研究项目(M2020207)。

作者简介: 李振江(1999—),男,硕士研究生,研究方向为智能医疗信息处理; 魏德健(1985—),通讯作者,男,副教授,硕士生导师,CCF 会员,研究方向为中医药智能化,E-mail:289608678@qq.com; 冯妍妍(1999—),女,硕士研究生,研究方向为中医药智能化、医疗健康大数据; 于丰帆(1999—),女,硕士研究生,研究方向为智能医疗信息处理; 马一凡(1999—),女,硕士研究生,研究方向为智能医疗信息处理。

表面肌电(sEMG)是运动过程中受刺激所产生在皮肤表面的生物电信号,是由采集电极所募集的运动单元动作电位(MUAP)与噪声叠加而成。该信号可直接反映肢体运动的肌肉收缩状态,并从中解码出运动直接关联的意图。目前用于运动分析研究的肌电信号主要有两种:针电极肌电信号(iEMG)和表面肌电信号(sEMG)。iEMG为局部信号,具有一定的稳定性,但采用侵入式方法,会对受试者造成一定伤害,多用于临床测试。sEMG采用非侵入方法,采集简单,广泛用于手势分类^[1,2]、肌电接口^[3,4]、机器人控制^[5]、智能假肢手^[6]、肌力估计^[7]等方面,为更便捷的人机协作提供了新思路。

机器学习(ML)和深度学习(DL)在数据处理方面的能力,使人机交互(HCI)系统具有主动感知人为意图的能力,有利于实现人机的自然、直觉与准确交互^[8]。基于sEMG的手部动作识别逐渐成为HCI的研究热点,一度被认为是新兴、有潜力的HCI领域,具有广泛的应用前景^[9]。在人机交互方面,可以实现智能假肢手代替部分人手功能,完成智能设备代替仿生人手的各种功能需求^[6]。可通过手势识别控制机器人进行移动、抓取等^[5],提高机器人的灵活度和智能程度。利用手势动作来实现智能家居控制,识别门禁系统^[10]等,让用户更加便捷地控制家居设备;在健康监测方面,利用肌电信号对大型手部手术后康复与治疗恢复^[11,12]、临床医学手部肌肉功能状态的评价^[13]等具有极大的参考价值。通过手部识别技术监测手部运动状态,为手部疾病早期诊断和治疗提供参考^[14];在虚拟现实方面,通过手部动作控制游戏角色^[15,16],提高游戏沉浸感。通过手势进行虚拟键盘和鼠标操作^[17,18],提高工作效率。

基于sEMG的手部动作识别研究成果已经在各个领域得到了广泛的应用,不断为人们的生活和工作带来更多的便利和效率。

在将sEMG信号识别出的手部运动意图制造成智能假肢手的过程中,面临着众多的困难。如何将sEMG转化为反映人体运动意图的信号是创造智能假肢手的关键^[19],如何减少训练所需的时间和精力成为智能假肢手在产业化过程中所面临的重要问题^[20],如何让截肢者利用残留手臂sEMG来控制智能假肢手是需要解决的核心问题之一^[21]。通过解决上述问题,实现精确的基于sEMG手部动作识别方法,促进智能假肢手的发展,帮助截肢者恢复部分手部功能。因此,基于sEMG的手部动作识别成为最具前景的上肢神经假肢控制方法^[22],并且手势识别(HGR)系统可以通过各种有效算法模型对各种手势进行直观、准确识别^[23]。

基于上述问题,本文对sEMG手部动作识别的研究进行介绍和总结。论文主要结构如图1所示,将相关文献和论文分成四个部分进行分析总结:(1)手部动作识别常用数据集和肌电数据采集介绍。(2)基于机器学习的手部动作识别研究,介绍了LDA、KNN、SVM在手部动作识别的研究结果与进展。(3)基于深度学习的手部动作识别研究,重点介绍了比较流行的CNN、RNN、TCN网络模型,介绍各模型的优点和不足。(4)基于混合网络结构的手部动作识别,将神经网络结构与物联网技术、稳态视觉技术和超声波技术相结合,总结各混合网络结构识别精度与模型复杂度。最后全文分析了当前研究及应用中存在亟待解决突破的关键问题,并提出一些有助于sEMG手部动作识别技术革新的切入点,为后续研究提供借鉴。

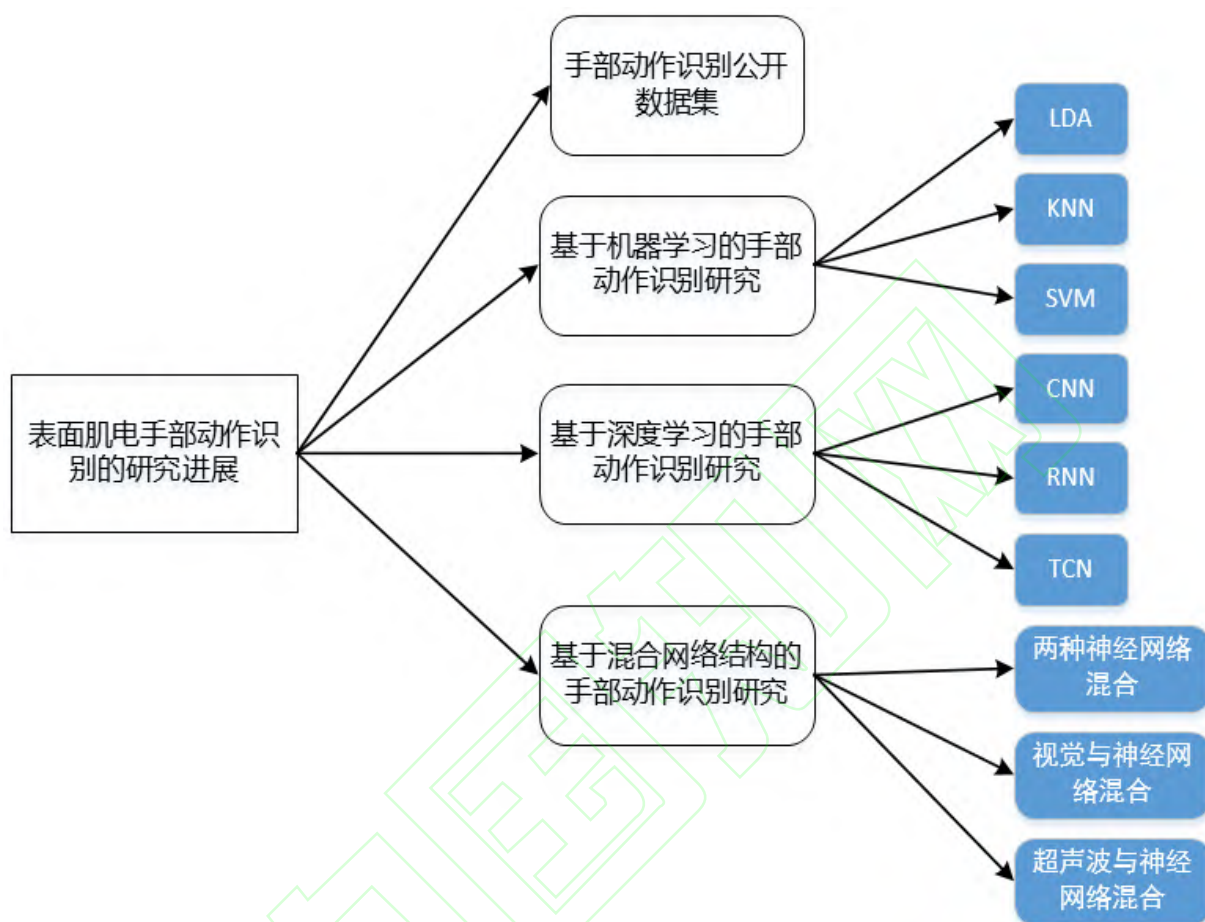


图1 表面肌电手部动作识别研究进展内容结构

Fig.1 Advances in Surface Electromyography for Hand Movement Recognition Content Structure

1.数据集介绍

手部动作肌电图 (EMG) 是研究手和上肢运动规律, 实现智能假肢手的重要组成部分。为研究运用 ML 和 DL 实现手部动作模式识别提供了数据来源。本章将对近几年文献中常见的 sEMG 样本集进行介绍。

1.1 NinaPro DB

NinaPro^[24]是一个公开可用的多模式数据集, 该数据集包括 300 多个样本, 分为 10 个数据集, 在全球范围内被机器学习、机器人、医学和神经科学领域的研究人员使用, 绝大多数国内学者运用该数据

集开展基于 sEMG 的动作识别研究。本节重点介绍 NinaPro 中几个常用数据子集, DB1 包含 27 名健康受试者的 52 种不同手部运动 EMG, 其中包括等长、等张手部收缩运动, 等长收缩为保持肌肉长度, 不进行任何运动。等张收缩为肌肉进行向心收缩和离心收缩运动^[25]。等长、等张收缩示意如图 2; DB2 包括 40 名健康受试者的 49 种不同的手部动作 EMG, 其包括手指、手腕功能性运动; DB3 为 11 名经桡动脉截肢者受试者的 EMG; DB5 为 10 名健康受试者执行的 52 种不同手部运动 EMG。该数据集为手部动作识别研究提供了主要的数据来源。




图2 文献[20]等长、等张肌肉收缩示意图
Fig.2 Schematic diagram of isometric and isotonic muscle contraction in [20]

1.2 BioPatRec26MOV

利用开源软件 BioPatRec^[26]的高度模块化和可定制的平台, 提供一个公开可用的肌电信号存储库。该数据集使用 8 个表面电极收集 17 名健康受试者的 26 种手势动作对应的 sEMG, 这些数据引起了其他学科(如人工智能、媒介学、增强现实等)的研究人员和学生对假肢控制的兴趣。此外, BioPatRec 被用作生物电信号处理和模式识别的教学工具。

1.3 UCI

UCI^[27]是一个常用的机器学习标准数据集, 该数据集以 500Hz 的采样率, 采集 5 名年龄在 20-22 岁受试者 (3 名女性, 2 名男性) 的 6 种不同的手势 sEMG。每个手势采集时间 6s, 每个动作重复 30 次。

该数据集包括自由抓取、重复抓取以及指间关节动作的肌电数据, 适用于实现手部连续动作的模式识别。

1.4 CSL-HDEMG

CSL-HDEMG^[28]是针对高密度表面肌电 (HD-sEMG), 建立的专有手势识别标准数据集, 可以通过覆盖在肌肉上的电极来记录 sEMG 时空上的信息, 无需进行精准定位。数据集中数据采用 192 个电极阵列, 记录 5 名健康受试者的 27 种手势上臂肌肉肌电信号^[29], 其中大部分手部动作为手指的伸展和弯曲, 包括一个放松的手势。该数据集为手指识别控制, 后续手部动作更加灵活控制提供了一个数据基础。动作如下图 3:




图3 27 种手势分为三组: 触控、弯曲、多指^[28]

Fig.3 27 gestures divided into three groups: Tap-Set, Bend-Set, and Multi-Finger-Set in ^[28]

1.5 CAPG-MYo

CAPG-MYo^[30]是基于sEMG的手势检测最新进展,开发的一组用于交互预测的定义手势。利用CAPG臂带捕获受试者的sEMG和IMU信号,以构建自定义手势的小型多源信号数据集。CAPG-MYo数据集^[31]包含来自23名健康受试者的128通道HD-sEMG,它由3个子数据集组成:(1)DB-a:从23名受试者中挑选18名受试者测量8种等长和等张手势运动EMG,每个手势保持3-10s。(2)DB-

b:与DB-a为相同的手势,从23名受试者中挑选10人获得的EMG,每个手势保持3s。(3)DB-c:从23名受试者中挑选10人获得12个手指基本动作EMG,每个手势保持3s,三个子数据集手势如图4所示。CAPG-MYo数据集为研究下一代肌肉-计算机接口(MCI)带来了新的可能性,为比较手势识别算法和开发HD-sEMG的MCI提供了一个数据基础。数据集的具体介绍可以参考:<http://zju-capg.org>



图4 (a)为DB-a和DB-b中手势;(b)为DB-c中手势
Fig.4 (a) for gestures in DB-a and DB-b; (b) for gesture in DB-c

1.6 自测数据集

尽管人的肌肉和骨骼分布大致相同,但不同个体之间存在着诸多肌电信号的差别^[32],如不同个体在执行相同动作时,肌肉收缩方式和收缩力度的大小等方面都具有差异,这些差异都极大的限制了智能假肢手在商业应用的推广。为解决个体间的差异,可以通过采集个体EMG形成自测数据集,提高手部肌电信号分析的精度和可靠性。个性化的肌电信号可根据不同的应用场景和需求进行定制,具有广泛的应用前景。

肌电信号的采集方法有侵入式和非侵入式两种。侵入式方法(iEMG)是一种将针电极插入皮肤的测量方法(测量方式如图5),因其对受试者造成一定伤害,多用于临床测试。非侵入式方法(sEMG)是通过附着在皮肤上的电极获取肌电数据,因其无创、

采集简单,而被广泛用于手部动作识别研究^[33]。




图5 侵入式肌电信号采集^[34]
Fig.5 Invasive EMG signal acquisition^[34]

本文所用的肌电信号为sEMG,在自测手部动作数据集时,肌电采集流程为:首先在采集sEMG信号前,让测试者清洁皮肤表面,去除汗渍、皮脂和毛发等物质,以保证肌电电极与测试者肌肉表面充分接触,来提高sEMG的质量和稳定性。在进行

sEMG 采集时, 需要确保受试者肌肉保持放松状态或进行特定的肌肉活动, 避免任何干扰因素。其次在肌电采集过程中, 对 sEMG 信号进行降噪一直是比较热门的课题^[35], 为降低电极本身固有的噪声, 可采用 Ag/AgCl 制成的电极, 来降低电极噪声干扰^[36]。在确定最佳电极放置位置后, 粘贴电极时可通过使用导电凝胶或导电贴片, 来保证良好接触, 降低环境噪声干扰。连接肌电电极到放大器电缆以及电极和皮肤接口的移动会产生运动伪影, 造成运动噪声干扰, 可通过嵌入式电极来有效的去除运动伪影^[35]。去除运动伪影干扰后, 肌电电极捕获的 sEMG 经过放大电路放大(如图 6), 再经过 A/D 转化后输入计算机^[32]。最后将采集的 sEMG 进行数据预处理, 以便后续分析与应用。




图 6 采集 sEMG 信号
Fig.6 Sampling sEMG signals

在文献[37]中, 使用 Thalmic Labs 的一款低成本无线 Myo 臂带, 测量 13 名健康受试者 (8 名男性, 5 名女性) 的 21 种常见手势, 每种手势重复 30 次, 重复之间 2s 休息时间, 不同手势有 5min 休息时间。这些手势由前臂上几块主要的肌肉牵引力控制, 并存在高度的视觉相似性。21 种手势示意如图 7 所示, 相关数据集材料可参考: <https://github.com/ChauncyHe/HandGesturePrediction>



图 7 A01-A20 为 20 种不同的手势, R 代表放松手势
Fig.7 A01-A20 are 20 different gestures, R stands for relax gesture

在文献[38]中, 用 Myo 臂带收集 EMG, 其中数据来源于年龄在 22-60 岁之间 3 名男生和 5 名女生的 7 种不同手势肌电数据, 每个手势重复 30 次, 每次数据记录持续 5s。其中的手势主要为握拳、手指展开、向内、向外、内旋、外旋和休息。7 种手势动作如图 8 所示, 相关材料可参考: <https://doi.org/10.1016/j.irbm.2022.06.001>.




图 8 7 种手势动作示意图
Fig.8 Schematic diagram of 7 gesture movements

综上所述，对文献中用到的数据集总结如表 1：

表 1 肌电数据集总结
Table 1 Summary of EMG datasets

名称	介绍	是否公开
NinaPro DB1 ^[29]	27 名健康受试者，52 种不同手势重复 10 次的 EMG	是
NinaPro DB2 ^[22]	40 名健康受试者，49 种手部动作（8 种等长和等张手部构型；9 个基本手腕动作；23 个抓握和功能性动作，9 种力型）重复 6 次的 EMG	是
NinaPro DB3 ^[22]	11 名经桡骨截肢的受试者 EMG	是
NinaPro DB5 ^[27]	10 名健康受试者的 53 种不同手部动作重复 6 次的 sEMG	是
UCI ^[27]	6 名健康受试者（3 名女性和 3 名男性）的 6 种抓握的 EMG	是
CAPG-MYo ^[39]	23 名健康受试者的 128 个通道的 HD-sEMG	是
CSL-HDEMG ^[31]	192 个电极阵列记录 5 名健康受试者的 27 个手指手势 EMG。	是
BioPatRec26MOV ^[26]	17 名健康受试者的 26 个手势动作 EMG	是
21 种常见的手势 ^[37]	13 名健康受试者（8 名男性和 5 名女性），21 种常见手势 EMG	是
7 个手势 ^[38]	3 名男生和 5 名女生，年龄 22 到 60 岁，7 种手势 EMG	是

sEMG 手部动作识别研究的主要集中在特征提取和模型分类两个方面，特征提取主要是对原始信号进行平滑、归一化处理，后利用滑动窗口进行分割，获得隐藏在 sEMG 信号中的特征向量，如时域、频域、时频域等特征^[1]，并去除不需要的部分干扰信息^[40]。模型分类是利用算法模型对手部 sEMG 信息进行分类，并将信息分配到预定义类别或标签的过程。基于机器学习的手部动作识别方法需要特征提取工程，而在特征提取过程中可能导致有用信息丢失^[37]，致使机器学习识别的准确率不高。而基于深度学习的手部动作识别方法将特征提取和模型分类两个过程相融合，直接处理原始 sEMG 信号，减少了特征提取过程中有用信号丢失和信息冗余等问题，促进了基于 sEMG 手部动作识别研究的发展，让智能假肢手交互变得更加自然、高效。

2 基于机器学习的手部动作识别研究

传统机器学习模型在基于 sEMG 的手部动作识别研究领域已得到成熟的应用，将 LAD^[41, 42]、KNN^[43]、SVM^[44]等方法用于手部动作识别研究取得了显著进展^[45]，基于机器学习的手部动作识别流程如图 9 所示。在训练集足够大的情况下，基于 ML 的手部动作识别模型具有较高的识别准确性和泛化能力。但 ML 方法主要以浅层特征为主，特征信息需要专业知识经验和人为选择，可靠性有待进一

步提升^[46]，手部动作识别的结果受特征选择、电极数量和位置的影响。此外，基于机器学习的手部动作识别对新数据的适用能力弱、算法复杂度高以及泛化能力弱，这些问题阻碍了手部动作识别研究的自动化、智能化发展。



图 9 基于机器学习手部动作识别流程图
Fig.9 Machine learning based hand movement recognition flowchart

2.1 基于 LDA 的手部动作识别研究

线性判别分析（LDA）是一种经典的线性学习方法。方法通过降维投影，使不同类数据相距较远，同类数据相距较近，以此来实现手部动作的分类。LDA 模型通常需要从 sEMG 中提取特征作为模型的输入，模型计算量小、速度快，但分类精度较低。

针对 LDA 模型需要处理大量手势 sEMG 的状况，Duan 等人^[47]对三通道表面肌电信号的 9 种手势进行分类，对提取的均方根比（RMSR）特征，采用 LDA 模型，平均识别准确率 91.7%，该模型用较少的传感器数据来识别更多的手势，但忽略了肌电信号的非理想情况。而 Naik,G,R.等人^[48]用主成分分析（PCA）对手指屈伸数据进行降维，后用独立分

量分析 (ICA) 对特征进行权重分离, 采用 LDA 对手部伸屈动作进行分类, 避免了数据训练不足和训练过度的干扰, 分类准确率达 90%, 该识别方法将 PCA 与 LDA 相结合, 降低了数据的复杂性和冗余性, 提高了数据处理的效率和准确性, 但忽略了模型的鲁棒性。为解决手部肌电信号识别精度较低的情况, Qi 等人^[3]将 LDA 和极限学习机 (ELM) 应用于手部动作识别, 减少 sEMG 中的冗余信息, 采用特征重提取方法提取的特征图斜率 (CMS), 加强了跨时域特征关系, 提高跨时域识别的可行性, 该实验减少了手势识别过程中时间差的影响, 提出的框架在保证模型鲁棒性的同时, 还可以在长期使用中, 提高了人机交互的泛化能力。

由上述分析可知, 与其他分类模型相比, LDA 模型具有较小的计算量, 在实现方面可与其他数据处理算法相结合, 降低识别的计算量。LDA 对线性可分数据分类效果较好, 对复杂的非线性和非理想情况下的肌电信号分类问题不太适用, 模型的鲁棒性较差。但 LDA 与其他特征提取的方法相结合进行模式识别仍然具有一定的研究价值。

2.2 基于 KNN 的手部动作识别研究

K 最近邻分类算法 (KNN) 属于监督学习算法, 模型算法建立在最近邻算法上, 主要是通过考虑 sEMG 数据集与训练集中样本的相似性进行分类来实现手势识别。

为测试基于 KNN 手势识别模型受特征选择结果的影响, Narayan 等人^[43]利用 KNN 模型对六种手部动作进行特征识别, 利用离散小波变换去噪, 提取频域 (FD)、时频域 (TFD) 特征, 后用 KNN 对两类特征进行识别, FD 识别率为 89%, TFD 达 95.5%, 该实验结果表明了当选择合适特征的 KNN 模型, 可以大幅提高手部动作识别的准确性, 但忽略了模型实时性。为解决模型实时预测效果较差的情况, Marco 等人^[49]用 Myo 臂章式机电传感器测量前臂肌肉的 sEMG, 同时对 sEMG 进行活动检测来保证信号瞬时性, 利用 KNN 和动态时间规整算法 (DTW) 对肌电信号进行分类, 实现了实时预测的效果, 可根据手部肌电信号的实时反馈, 应用于患者的手部运动康复, 帮助患者正确执行运动和恢复肌肉功能。

为将基于 KNN 的手势识别研究成果应用于截

肢者的日常生活中, 部分研究人员研究性别、环境等因素对 KNN 手势识别效果的影响。在以往研究中, 极少考虑性别对手势识别的影响, Bergil 等人^[50]针对这种情况, 采用 KNN 模型对六种基本的手势进行分类, 获得男性和女性的手部动作准确率分别为 96.67% 和 92.78%, 该实验可用于评价性别对分类性能的影响, 对根据性别因素设计智能假肢手具有一定的参考价值, 但模型需要训练大量数据, 在小数据集上难以获得满意的识别精度。在日常生活应用中, 一些截肢者需要使用假肢手进行水下作业, Xue 等人^[36]将 Tucker 张量分解用于 sEMG 信号的特征提取和识别, 无需大量训练数据, 解决了水下 sEMG 信号识别问题, KNN 识别准确率达 96.43%, 该实验方法有助于提高水下 sEMG 信号的识别精度, 为假肢手在水中的应用提供了依据。

由上述分析可知, KNN 模型简单易用, 在选择合适特征后, 具有较高的识别准确度。但模型在分类时, 需要对所有数据进行计算, 计算代价高。与此同时, 模型对肌电信号的实时性预测效果不佳。模型在评估受试者性别对手势识别影响方面具有一定参考价值, 也为智能假肢手在水下环境中的应用提供了依据。

2.3 基于 SVM 的手部动作识别研究

支持向量机 (SVM) 是一种有监督的机器学习方法, 是一种二分类模型。在线性分类中, 将标记数据映射到一个向量空间, 确保类间间隔最大化; 在非线性分类中, 使用核函数将样本从原始低维特征空间映射到高维空间, 从而使数据在高维空间中可以被线性可分^[27]。

基于 SVM 的手部动作识别多为上臂大幅度的识别研究, 而对单个手指动作分类研究较少, chen 等人^[51]对手指动作识别进行研究, 将时域特征 (TD)、自相关和互相关系数 (ACCC)、谱功率幅值 (SPM) 三种常见特征类型结合起来, 用多核学习支持向量机 (MKL-SVM) 进行离线识别, 准确性高达 97.93%, 促进了手部动作识别向更加灵活的方面发展。由于手指比较灵活, 采集时会导致移动次数增加, 造成运动伪影, 使准确分类成为一个严峻的问题。在文献[52]中, 使用最小二乘支持向量机 (LS-SVM) 对 52 种手部动作进行识别, 采用二次加窗法和 4 个不同时域特征, 获得了 85.19% 的最佳分类精度, 在实

验中发现随着移动次数的增加,肌电假肢会更加人性化。

在以往的 SVM 模型研究,手部动作识别准确率普遍不高,蔡芝蔚^[53]针对这种现象,使用 SVM 模型对特征进行提取,将 ANN、HMM 和 DTW 三种算法形成组合优化模型进行手势识别,识别的准确率达 90%以上,但模型较为复杂,优化所花时间较多,容易在训练数据时出现过拟合现象,也未考虑模型实时性问题。后来 SVM 手部动作识别研究在兼顾准确率的同时,也针对实时性问题,对 SVM 模型做出调整。文献[38]提出一种实时分类模型对受试者数据进行泛化训练,用 Cubic SVM 对平均绝对值(MAV)特征进行实时分类,准确率达 99.05%,

该方法提出了一种实时分类模型训练的思想,在考虑实时预测的同时,有良好的手势识别效果,具有广阔的商业应用前景。

由上述分析可知,在理想情况下,SVM 可以识别大量的手部动作,在灵活的手指动作识别方面,具有较高的识别准确率。但 SVM 模型复杂,需要大量的计算资源,容易导致模型出现过拟合现象。在运动状态转换的过程中,也很可能出现不稳定的预测行为。但 SVM 模型具有较好的实时预测效果,为复杂手部肌肉信号的识别提供了新思路。

综上所述,基于机器学习手部动作识别的研究总结如表 2 所示。

表 2 基于机器学习手部动作识别的研究总结
Table 2 Summary of research on machine learning based hand movement recognition

文献	解决问题	应用模型	改进方法	选择特征	分类准确性
Duan 等 ^[47]	肌电信号传感器数量过多	LDA	采用三通道表面肌电信号的时域特征、RMSR 和 AR 模型	RMSR	91.7%
Naik,G,R. 等 ^[48]	训练过度和训练不足	LDA	利用 PCA 处理数据,然后用 ICA 定义权重矩阵	RMS	90%
Qi 等 ^[3]	LDA 手势系统无鲁棒性,提高模型泛化能力	LDA+ELM	用 CMS 特征减少时差,提出手势识别的鲁棒性框架	CMS	79.3%
Narayan 等 ^[43]	KNN 的合适特征选择问题	KNN	用 DWT 去噪和 TFD 特征提取	PSD TFD	FD :89% TFD:95.5%
Marco 等 ^[49]	肌电信号的实时性	KNN+DTW	用 Myo 采集 sEMG,并使用 KNN 和 DTW 来进行识别	自定义两个类型特征矩阵	89.5%
Bergil 等 ^[50]	使用有监督和无监督分类	KNN	小波分解提取特征,PCA 降维	降维后的 20 维特征集	男: 96.27% 女: 92.78%
Xuc 等 ^[36]	智能假肢手下水操作以及需要大量训练数据	KNN	通过 Tucker 张量分解提取 sEMG 信号特征	时域、频域和张量分解提取特征	96.43%
Chen 等 ^[51]	多手指动作自动分类研究	MKL-SVM	开发离线识别算法,对 TD、ACC、SPM 特征采用 MKL-SVM	TD、ACCC、SPM	97.93%
Maleki 等 ^[52]	移动增加,分类精度下降	LS-SVM	用二次加窗方法和 4 个不同时间特征	IVA、MAV、RMS、WL	85.19%
蔡等 ^[53]	SVM 模型识别率不高	SVM	用 SVM 特征提取,用 ANN、HMM 和 DTW 三种算法形成组合优化模型	手形识别特征	达 90%以上
Tepe 等 ^[38]	sEMG 信号的实时性和非实时性	SVM Cubic SVM	非实时分类选取 RMS 和 IEMG; 实时分类选取 MAV	非实时: RMS、IEMG 实时: MAV	非实时最高为 96.38% 实时最高为 99.05%

3 基于深度学习的手部动作识别研究

与机器学习模型受特征提取过程的影响,难以区分相似手势之间的细微差距,深度学习模型在手

部动作识别领域显示了广阔的应用前景^[54]。深度学习网络包括输入层、多个隐藏层和输出层,学习输入 sEMG 数据的高级特征^[21],其处理肌电信号的流

程如图 10 所示。基于深度学习的手部动作识别方法摒弃了传统机器学习方法中的手工特征提取环节,解决了机器学习方法预测连续手部动作效果较差等问题^[34]。此外,基于深度学习的手部动作识别方法具有更强的适应性、抗噪性和更好的泛化能力。然而,基于深度学习的手部动作识别模型计算复杂,需训练大量的数据^[21],并且模型迁移能力不强。




图 10 基于深度学习手部动作识别流程图
Fig.10 Deep learning based hand movement recognition flowchart

3.1 基于 CNN 的手部动作识别研究

卷积神经网络 (CNN) 是由输入层、一个或多个卷积层和池化层、全连接层以及输出层组成,其网络结构如图 11 所示。在深度学习网络结构中, CNN 网络可以从大量数据中自动学习手部肌电信号的特征并对其进行分类,是手部动作识别应用最广泛的分类网络之一。基于 sEMG 的手部动作识别通常被认为是基于 CNN 的图像分类。




图 11 CNN 网络结构示意图
Fig.11 Schematic diagram of CNN network structure

Ding 等人^[55]针对特征提取过程中分类精度下降的情况,提出了一种并行多尺度卷积手势识别体系,采用更大的核滤波器,在 NinaPro 数据库上进行分类,模型的识别准确率明显提高,但也让 CNN 结构变得复杂,模型训练时间变长,计算成本增加。针对此类情况,chen 等人^[56]设计了一个紧密的 CNN 模型 EMGNet,模型平均识别准确性为 98.1%,该模型在提高分类精度的同时,也降低了模型的复杂度。而文献^[57]中,作者利用迁移学习减少个人数据生成负担,用专门的 MC Dropout 层,解决了小数据集上的过拟合现象,平均识别率达 97.81%,该实验也证明了模型的鲁棒性与精确性。研究者通过不断优化算法模型,进行迁移学习等方式,来减少模型训练时间,达到更好的预测效果。

在后续的手势识别研究中,研究者发现当测量肌电的位置不同,会有不同的肌电信号。因此,HD-sEMG 便应运而生,它是一种利用二维密集电极阵列记录局部皮肤肌肉活动的方法,无需精准定位,便可以测量 sEMG 的时空信息。Geng 等人^[29]提出用 HD-sEMG 瞬时值在空间上构成 sEMG 图像的概念,用 CNN 网络对手势进行分类,识别的准确率

达 99.0%。Tam 等人^[58]利用 HD-sEMG 和 CNN 网络来对手势进行分类,通过迁移学习减少训练时间,与此同时在手部运动状态过渡期间中,没有模式切换的响应时间,保证了手部动作连续估计的实时性。HD-sEMG 促进了手部动作模式识别的发展,但也使 CNN 网络模型变得愈加复杂,计算成本不断增加,消耗大量时间和能量。Qi 等人^[59]针对以上情况提出一种新型 CNN 分类器,用无关数据来对网络进行训练加快收敛,减少训练时间,融合多个传感器数据,提高了模型的识别性能和泛化能力。

由上述分析可知,与传统的机器学习方法 (LDA、KNN、SVM) 相比, CNN 具有更高的分类精度,可自动从肌电数据中学习特征,减少了特征提取环节中有效信号的丢失。CNN 模型对手部 HD-sEMG 的动作识别,提高了手势识别研究的准确性和鲁棒性。但 CNN 模型需要计算大量的数据,耗时耗能较多,计算成本较贵。未来 CNN 模型在基于 sEMG 的手部动作识别领域仍具有巨大的潜力,其研究关键在于如何更好地融合多个传感器数据,来实现更好的手势识别效果。

3.2 基于 RNN 的手部动作识别研究

递归神经网络 (RNN) 主要是由输入层、输出层和隐藏层组成, 与 CNN 不同的是 RNN 可以接收上一个时间点的隐藏层状态, 把网络按照时间线展开如图 12 所示。RNN 在全连接神经网络的基础上

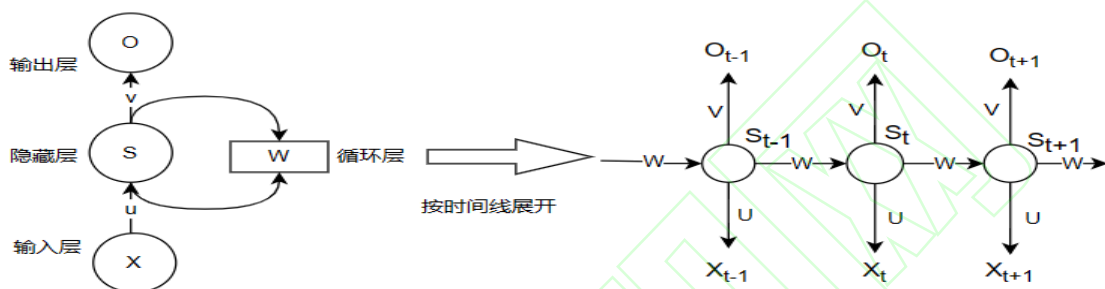


图 12 RNN 按时间线展开图
Fig.12 RNN expanded by timeline

与 CNN 不同, RNN 将 sEMG 看作时间序列, 可以从相邻的输入中获得信息, 并提取 sEMG 的时间信息用于意图识别^[5]。Zhang 等人^[37]提出一种新型 RNN 模型, 能够对肌电信号的前采样时间步长进行编码训练, 分类的准确性达 89.6%。RNN 在进行预测时, 不能记住很早之前的 sEMG 信号, 容易发生梯度消失, 无法从 sEMG 信号中得到精确的预测值。而对 RNN 改进后的长短期记忆网络 (LSTM) 通过它内部的“门”确定前面信息保留或丢弃的比例, 来降低梯度消失发生的概率。Samadani 等人^[60]通过比较几种手部动作识别模型算法, 发现双向 LSTM (BiLSTM) 对 NinaPro DB2 中数据分类准确率高达 86.7%。文献[61]中, 通过改进 RNN 网络, 使用 LSTM 和门控制递归单元 (GRN) 来对前臂肌电信号的手势进行在线分类, 在 Dualmyo 和 Ninapro DB5 数据库上的识别准确率分别为 95%和 91%。在文献[62]中, 作者提出了利用 LSTM 对 6 种连续抓取动作进行估计, LSTM 估计的角度更符合目标角度。实验发现, LSTM 模型能很好的估计连续手部运动, 让智能假肢手完成类人的连续平滑运动, 实现多种

增加了前后时序上的关系, 更擅长处理时间、空间、顺序以及无标记数据。因 sEMG 信号是一种时间和空间维度的信号, RNN 模型由于其对时间依赖性的处理能力和对序列特征的提取能力, 可以通过分析肌电信号在时间和空间上的特征来了解肌肉活动的特点, 进行手部动作识别。

服务^[32]。

由上述分析可知, RNN 更适合处理 sEMG 序列数据, 改进的 LSTM 分类器具有较强的记忆能力, 能从过去输入的 sEMG 中完成模型的训练, 对手部动作进行综合预测, 且对连续手部动作的预测具有较好的效果。由于 RNN 模型需要存储隐藏层状态, 训练时需要大量内存, 也无法实现实时性应用。但鉴于 RNN 模型对序列建模的功能, 未来 RNN 手部动作识别在人机交互、虚拟现实领域具有广泛的应用前景。

3.3 基于 TCN 的手部动作识别研究

时域卷积神经网络 (TCN) 是用来学习输入序列中隐藏时间依赖关系的一种序列预测算法模型。它能利用一维卷积层沿时间维度来学习输入信号的时间依赖, 有利于处理肌电信号, 而被逐渐应用于手部动作识别研究。

TCN 提取肌电信号时序、层级特征 (如图 12 所示), 给定长度为 N , $\{x\} = \{x_0, \dots, x_{N-1}\}$ 的输入序列, 通过因果卷积层的输出为 $\{y\} = \{y_0, \dots, y_{N-1}\}$,

使得 $y_n(n<N)$ ，仅依赖与 $\{x_0, \dots, x_n\}$ 。扩张卷积公式^[63]为：

$$y_n=(X*_dh)_n=\sum_m x_{n-dm}h_m$$

其中 $*_d$ 为扩张卷积算子， d 为扩张因子， h 为滤波器的脉冲响应。




图 13 TCN 的肌电信号时序、层级特征提取框架^[8]
Fig.13 TCN for myoelectric signal timing, layer-by-layer feature extraction framework in [8]

近年来将 TCN 应用于基于 sEMG 的手势识别领域，并展现了良好的预测效果。在文献[63]中，将基于 sEMG 的手部动作识别看成序列分类问题，提出了完整的 TCN 分类模型体系结构，提出的 TCN 网络模型在手势识别方面提高了近 5%，但忽略了网络模型的稳定性。Betthausen 等人^[64]在提高识别准确率的同时，通过适应性强化训练来增加网络的预测性能，提高网络稳定性，利用 TCN 对肌电图中时域信息进行预测，按帧处理后的分类结果为 72.1%。而在

文献[65]中，在保持模型分类准确率较高的情况下，用 TCN 网络模型解决了瞬态肌肉运动过渡期间预测不稳定的情况，降低了预测延迟。TCN 促进了手势识别朝着精确、稳定预测的方向发展。

随着研究者对 TCN 用于手部动作识别的研究，发现多数 TCN 网络存在着结构复杂，训练时间长，占用内存大等情况。随着硬件的发展，研究者尝试将 TCN 网络结构轻量化，以便进行嵌入式开发，缓解耗时和所占内存问题。在文献[66]中，提出一种新型 TCN 方法，内存占用率少 120 倍，精度仅降低 2.5%，适合资源受限网络的嵌入式开发。而在文献[67]中，提出基于 TCN 的新型拓扑结构（TEMPONet），将 TEMPONet 移植到 8 核物联网处理器（GAP8）上，获得平均 93.7%的准确率，GAP8 采用量化的方式来适应内存约束，实现低功耗的同时，性能仅下降 3%，推动了手部动作识别研究可穿戴嵌入式系统的发展。

由上述分析可知，TCN 模型既具有对序列建模的功能，又具有 CNN 的良好性能，避免了 RNN 模型中常见的梯度消失、梯度爆炸等缺陷。在稳态和瞬态肌电预测中的稳定性和分类精度明显高于其它模型，且 TCN 网络模型更适合便携式开发。TCN 为连续运动下瞬态预测以及运动过渡期间预测，低能耗手部动作识别模型、嵌入式开发、多自由度（multi-DOF）回归，开辟了新的研究方向。

综上所述，基于深度学习手部动作识别的研究总结如表 3 所示

表 3 基于深度学习手部动作识别的研究总结
Table 3 Summary of research on deep learning based hand movement recognition

文献	解决问题	模型	改进方法	年份	识别准确率
Ding 等 ^[55]	解决特征提取中信息丢失造成的精度下降问题	CNN	并行多尺度卷积结构，采用更大尺寸的核滤波器	2018	平均识别率最高为 83.79%
Chen 等 ^[56]	解决模型中含大量参数问题	CNN	设计一款紧凑的 CNN 模型 EMGNet	2020	平均识别率为 98.81%
Côté-Allard 等 ^[57]	模型训练大量数据所消耗的计算机时间	CNN	用迁移学习技术增强了 CNN 模型	2017	平均识别率达 97.81%
Geng 等 ^[29]	sEMG 信号振幅波动，无法识别瞬时肌电信号	CNN	引入了由 HD-sEMG 组成的表面肌电信号空间图像	2016	最高识别率达 99.0%
Tam 等 ^[58]	缺少直观性和易用性、响应速度慢、无实时评估指标	CNN	利用 HD-sEMG 和 CNN 来适应每个独特用户的收缩模式，提出一种迁移学习	2021	准确率 97.17% 比传统非迁移学习时间较少 89.4%

Qi 等 ^[59]	研究不能识别复合运动，并灵活的应用于不同类型运动	CNN	定义一种新的“sEMG Image”图像来表示复合运动，对 CNN 简单修改，融合多个传感器	2020	识别率达到 94%-97%
Zhang 等 ^[37]	解决分类器过于依赖 sEMG 特征提取	RNN	训练后的模型输出前一个采样时间步长的表面肌电信号的瞬时预测	2020	89.6%
Samadani 等 ^[60]	不同 RNN 配置的比较，评估 LSTM 和 GRU 的 RNNs	LSTM GRU	用 BiLSTM，注意机制分类器，学习速率训练分类器进行性能评估	2018	BiLSTM: 89.5% 注意机制和逐步学习网络: 86.7%
Simão 等 ^[61]	解决在线手势分类对数据流的动态分类问题	LSTM	用 FFNN 对静态分类，LSTM 和 GRU 对动态分类	2019	最高为 95%
Wang 等 ^[62]	对抓取动作连续估计	LSTM	用 SPGP 和 RBF 的系数，对抓取进行连续估计，使用 Pearson 相关系数(CC)、RMSE 和 NRMSE 对真实关节进行评估	2020	LSTM 的 CC 超 SPGP 和 RBF 20% LSTM 的 RMSE 比 SPGP 或 RBF 小 20% LSTM 的 NRMSE 小于 SPGP 和 NRMSE
Tsinganos 等 ^[63]	无法处理任意长度序列，占用内存大	TCN	将 sEMG 看成是一维卷积的时间序列	2019	在手势识别方面提高了近 5%
Beththausen 等 ^[64]	基于数据帧压缩对分类瞬时特征导致的不稳定预测	ED-TCN	用运动预测增强 ED-TCN 模型，定义稳定性度量，自动分类标签编码，参数化序列模型自适应强化训练	2020	72.1%，明显高于 SVM
Zanghieri 等 ^[66]	表面肌电的长期可靠性问题和嵌入式识别精度下降	TCN+GAP8	开发 TCN 拓扑结构 TEMPONet 算法，并设计基于 GAP8 高效节能嵌入式平台	2020	93.7%
Beththausen 等 ^[65]	瞬态肌肉运动对 sEMG 时间结构的影响以及类间转换的不稳定	TCN	允许 27 个不同的 3-DOF 运动类同时进行，来计算超阈值位置，确定何时为瞬变状态	2020	TCN 和 LSTM 分类精度最高，但 TCN 比 LSTM 更稳定

4 基于混合网络结构的手部动作识别研究

基于混合网络结构的手部动作识别研究是将两个或两个以上网络结构或算法进行组合，通过对手部动作的 sEMG 进行学习，实现对手势动作的自动识别。混合网络模型在手部动作识别时往往表现出单一网络所不具有的优势，具有较强的鲁棒性和迁移能力以及较少的训练代价。但模型本身复杂，在后续参数调整、模型优化和扩展等方面存在很多困难。目前，大多数研究致力于开发出轻量化、低能耗的混合网络结构模型来识别手势动作。

利用混合网络来提取深度学习特征和手工提取特征，进行手部动作分类^[68]，表现出比传统识别更优异的结果。最近研究^[69]中，尝试将传统方式（SVM）与 CNN 相结合，利用 CNN 自动提取 sEMG 特征，后用 SVM 分类器对手部动作进行识别，混合后的网络识别准确性比 CNN 高 2.14%，比传统特征结果高 6.82%。后研究者尝试将两种深度学习网

络结构相结合，将 CNN 与 RNN 结合，获取 sEMG 的时空上的信息。Yu 等人^[70]尝试将注意力方式加入到 CNN-RNN 网络中，用深度学习框架提取 sEMG 不同通道之间的隐性相关，分类准确性达 94.5%。随着混合网络结构的不断复杂，计算成本和模型耗时耗能显著增加，迫切需要一个低能耗的平台，物联网和硬件技术的不断发展，缓解了此类现象。Bahador 等人^[39]引入了 Sensor-Wise 方法，该方法与 sEMG 和 CNN 结构高度相容，每一幅 sEMG 时间图像对应一个特定的传感器，且网络只有两个隐层，具有轻量级和较低的计算量，识别的精度高达 99.55%。将两种网络结构融合的方法提高了手部动作识别研究的准确性和可靠性。

目前，手势识别研究最好在有限复杂性和低能耗的环境中进行，识别过程最好能朝着满足患者直观性、自适性和鲁棒性实时控制的方向发展^[71]。将稳态视觉与手部动作识别相结合的方法能完全迎合以上两类情况，该方法是指通过稳态视觉器件，

将 sEMG 信号转换成可见的图像,以方便肌肉状态的观察和识别。针对无法直观观察人与智能假肢手的交互,计算机视觉的准确性过度依赖于环境情况。Ovur 等人^[72]提出一种融合深度视觉和 sEMG 优势的自主学习框架,将深度信息和 sEMG 与分层自组织映射(HSOM)和多层神经网络(MNN)相结合,利用MNN对sEMG进行分类,达到实时识别效果。针对手势收集和标记耗时耗能问题,Rahimian 等人^[73]开发出了一种基于视觉转换器(ViT)的神经网络体系(TEMGNet),解决了网络结构复杂性,混合的网络体系不需要预训练和微调,具备少量的可训练参数,在 NinaPro DB2 上的识别率高达 82.93%。将深度视觉与肌电图结合的手部动作识别是一种比较好的方案,为未来的人机交互提供了新方向。

多数手势识别的 sEMG 信号都是基于皮肤表面,无法对表皮以下的 sEMG 进行精准测量。目前有部分学者将超声波成像技术与神经网络模型相结合对手部动作识别进行了初步探索,能更好对深层肌电信号进行测量和识别。在文献[74]中,将超声波成像与手部姿势可穿戴设备相结合,来补偿跨时段位置移动导致的性能下降,利用超声波图像处理 and 神经网络对 10 种离散手势动作进行分类,准确率超

98%。Yang 等人^[75]也将超声波与手部动作模式识别相结合,利用超声波实现亚毫米的时空分辨率,来克服无法区分深层肌肉收缩和缺乏鲁棒性的分级信号,提高模型的实时性,用 LDA 和 SVM 两种网络对手势进行分类,测得的结果平均准确率超 98.5%。将超声波技术与基于 sEMG 的手部动作识别方法相结合,可以提供更直观、自然的交互方式,无需佩戴附加设备,可以更好地满足用户的需求,提高用户的体验,在虚拟现实、远程操作、医疗康复等领域的具有广阔的应用。

由上述分析可知,混合网络结构的手部动作识别,可以对手部 sEMG 信号的时空特征和多维度特征进行分析,并能发挥多个神经网络的综合优势,提高系统的总体预测性能,借助物联网技术,大大优化网络结构的复杂性,降低数据计算量,将分类器与稳态视觉和超声波技术相结合,提高 sEMG 手势识别的实时性和鲁棒性,未来手势识别的趋势是融合多个神经网络、稳态视觉和超声波技术,开发出一款便携、鲁棒性、泛化性强的系统。

综上所述,基于混合网络结构手部动作识别的研究总结如表 4 所示。

表 4 基于混合网络结构手部动作识别的研究总结

Table 4 Summary of research on hand action recognition based on hybrid network structures

文献	解决问题	应用模型	改进方法	识别准确率
Bahador 等 ^[39]	混合网络结构复杂,计算量大、耗能多	传感器+CNN	减少网络隐层个数,只有两个隐层	99.55%
Chen 等 ^[69]	识别精度不高	SVM+CNN	CNN 与 SVM 结合,CNN 用来特征提取,SVM 提高泛化能力	比传统提高 6.82% 比 CNN 高 2.14%
Yu 等 ^[70]	sEMG 信号缺少时空特征	CNN+RNN	将注意力机制加入混合网络 CNN-RNN	94.5%
Ovur 等 ^[72]	sEMG 不直观和视觉过度依赖环境	HSOM+MNN	将深度学习信息和 sEMG 与 HSOM 和 MNN 相结合	81.72%
Rahimian 等 ^[73]	需要大量数据集和网络具有复杂结构	TEMGNet	基于 ViT 的神经网络体系结构 TEMGNet	82.93%
McIntosh 等 ^[74]	跨会议位置导致 sEMG 信号准确性下降、实时性差	MLP	超声波与神经网络相结合	98%
Yang 等 ^[75]	区分深层肌肉收缩和缺少鲁棒性信号的分级信号	LDA、SVM	将超声波技术与手部识别相结合	平均识别超 98.5%

5 总结与展望

本文对 sEMG 手部动作识别研究的四个方面进行了综述。表面肌电在手部动作识别及应用领域体现了重要的研究价值,对推动手部动作识别研究发展具有重要意义。但肌电信号在实际应用中面临着诸多的非理想干扰因素,如抗干扰性差、个体差异性以及肌肉疲劳等,使得 sEMG 在手部动作识别的下一步研究中,面临着许多困难和挑战。本节主要对未来手部动作识别研究中需要解决问题和发展方向做了如下总结:

(1) 数据量缺乏。当前手部动作识别的 sEMG 信号,缺少一个动作全面、受试者年龄分布广的公开数据集。文献中所用的肌电数据多为小型数据集,数据集过小会导致训练模型出现过拟合现象,影响实际的预测准确性。为了解决此类问题,可以采集各个年龄受试者肌电信号,融合不同个体的多模态数据,进一步搜索相关数据,对数据集进行增强扩展。

(2) 肌电信号的抗干扰性差和实时性研究少。手部肌电信号在采集时容易受环境、电极噪声和受试者疲劳状态的影响,这些都极大降低了信号的质量和可靠性。国外研究者很早就开展了 sEMG 信号的实时性研究,而国内的研究大多基于离散的数据,无法直接应用于连续的手部动作预测。针对这两种现象,可在肌电信号采集前进行规范化处理,信号采集时采用先进的滤波器和去噪算法,最大程度的保证有效信息的提取。

(3) 分类模型网络结构复杂,计算成本高。手部动作分类网络结构过于复杂,在训练数据时容易出现过拟合现象,会让网络训练的难度加大,无法更好的泛化到新的数据集上。训练时需要更多的计算资源,容易陷入局部最优解,导致梯度消失或梯度爆炸等问题,使得网络模型无法训练。为解决这类问题,应遵循奥卡姆剃刀原理,在设计网络结构时,需要权衡网络模型的准确性和复杂度,在模型能够较好拟合训练集的前提下,降低模型的复杂度,设计轻量化的网络结构。

sEMG 手部动作识别研究未来发展方向:

(1) 多模态数据融合。将 sEMG 与其他传感器采集的数据进行融合,可以提高手部动作识别的准确性和稳定性。同时,多模态数据融合还增加了对

手部动作的理解和分析,有利于探索更深层次的动作控制机制。

(2) sEMG 手部动作识别方法与稳态视觉、超声波技术相结合。稳态视觉技术可以实时观察肌肉运动和姿态变化,超声波技术可以实时测量肌肉形态和位移,肌电信号识别技术可以准确地获取肌肉运动信息,将基于 sEMG 手部动作识别方法与两种技术结合使用互相弥补缺点,实现多维度评估,得到更全面的手部肌肉功能信息,提高识别的精度和稳定性。

(3) 轻量化。在保证分类准确率的前提下,牺牲部分模型精确度来减小模型的体积和计算量,提高模型的运行效率和性能。轻量化的分类模型具有更快的运行速度、更低的耗能、更小的存储空间和更好的可移植性。轻量化后的模型能更好的进行嵌入式开发,与物联网技术结合进行识别分类,实现低功耗设备的功能。

(4) 实时性处理。在实际应用中,手部动作识别需要具备较高的实时性。因此,需要优化信号采集装置,研究快速、高效的肌电信号处理算法和采用硬件加速技术,以满足实时控制和交互的需求。

(5) 致力于手指动作识别。手指是人类最灵活的器官之一,手指动作识别也是手部动作识别中最难部分,手指肌肉的数量和灵活的运动方式,对肌电信号采集和识别算法要求更高。因此,在手指动作识别过程中,选择合适的肌电传感器,开发先进的预处理算法和识别算法,以提高手指动作识别的精度。手指动作的识别可以应用于康复、精密度高的手术过程,为用户提供了更加智能、自然的交互方式。

综上所述,表面肌电手部动作识别是一个具有重要应用价值的领域,下一步的发展方向包括多模态数据融合、将基于 sEMG 手部动作识别方法与稳态视觉、超声波技术相结合、实时性处理和手指动作识别等方面。这些进展将为手部动作识别的精确性、稳定性、实时性和灵活性等方面带来重要的提升。

参考文献:

[1] LI W, SHI P, YU H. Gesture recognition using surface electromyography and deep learning for prostheses hand: state-of-the-art, challenges, and future[J]. Frontiers in neuroscience, 2021, 15: 621885.

- [2] CHEN J, BI S, ZHANG G, et al. High-density surface EMG-based gesture recognition using a 3D convolutional neural network[J]. *Sensors*, 2020, 20(4): 1201.
- [3] QI J, JIANG G, LI G, et al. Intelligent human-computer interaction based on surface EMG gesture recognition [J]. *Ieee Access*, 2019, 7: 61378-87.
- [4] PARK K-H, LEE S-W. Movement intention decoding based on deep learning for multiuser myoelectric interfaces; proceedings of the 2016 4th international winter conference on brain-computer Interface (BCI), F, 2016 [C]. *IEEE*.
- [5] XIONG D, ZHANG D, ZHAO X, et al. Deep learning for EMG-based human-machine interaction: A review [J]. *IEEE/CAA Journal of Automatica Sinica*, 2021, 8(3): 512-33.
- [6] MEATTINI R, BENATTI S, SCARCIA U, et al. An sEMG-based human-robot interface for robotic hands using machine learning and synergies [J]. *IEEE Transactions on Components, Packaging and Manufacturing Technology*, 2018, 8(7): 1149-58.
- [7] Al Harrach M, Boudaoud S, Carriou V, et al. Multi-muscle force estimation using data fusion and HD-sEMG: an experimental study[C]//2017 Fourth International Conference on Advances in Biomedical Engineering (ICABME). *IEEE*, 2017: 1-4.
- [8] 李自由, 赵新刚, 张弼, 等. 基于表面肌电的意图识别方法在非理想条件下的研究进展[J]. *自动化学报*, 2021, 47(5): 15.
- ZI-YOU L, XIN-GANG Z, BI Z, et al. Review of sEMG-based motion intent recognition methods in non-ideal conditions[J]. *Acta Automatica Sinica*, 2021, 47(5): 955-69.
- [9] 王逸桐. 基于表面肌电信号的手势动作识别技术的应用研究 [D]; 延边大学, 2021.
- WANG Y. Application research on gesture recognition technology based on surface electromyography[D]; Yanbian University, 2021.
- [10] DIRACO G, RESCIO G, SICILIANO P, et al. Review on Human Action Recognition in Smart Living: Sensing Technology, Multimodality, Real-Time Processing, Interoperability, and Resource-Constrained Processing[J]. *Sensors*, 2023, 23(11): 5281.
- [11] SOHN R, SON J, HWANG H, et al. Steady-state visual evoked potential (SSVEP)-based rehabilitation training system with functional electrical stimulation[J]. *Journal of Biomedical Engineering Research*, 2010, 31(5): 359-64.
- [12] KONAR A, SAHA S, KONAR A, et al. EEG-gesture based artificial limb movement for rehabilitative applications [J]. *Gesture Recognition: Principles, Techniques and Applications*, 2018: 243-68.
- [13] MU D, LI F, YU L, et al. Study on exercise muscle fatigue based on sEMG and ECG data fusion and temporal convolutional network[J]. *Plos one*, 2022, 17(12): e0276921.
- [14] FRIGO C, CRENNAN P. Multichannel SEMG in clinical gait analysis: a review and state-of-the-art[J]. *Clinical Biomechanics*, 2009, 24(3): 236-45.
- [15] SAGAYAM K M, HEMANTH D J. Hand posture and gesture recognition techniques for virtual reality applications: a survey[J]. *Virtual Reality*, 2017, 21: 91-107.
- [16] Joselli M, Clua E. grmobile: A framework for touch and accelerometer gesture recognition for mobile games[C]//2009 VIII Brazilian Symposium on Games and Digital Entertainment. *IEEE*, 2009: 141-150.
- [17] RAHIM M A, SHIN J, ISLAM M R. Hand gesture recognition-based non-touch character writing system on a virtual keyboard [J]. *Multimedia Tools and Applications*, 2020, 79(17-18): 11813-36.
- [18] LI F, FEI J. Gesture recognition algorithm based on image information fusion in virtual reality[J]. *Personal and Ubiquitous Computing*, 2019, 23: 487-97.
- [19] 赵新刚, 杨毕, 吴成东, 等. 基于表面肌电信号的人体运动意图识别方法研究[J]. 2009 全国虚拟仪器大会论文集(二), 2009.
- ZHAO X, HAN J, YANG B, et al. Research on the recognition method of human motion intention based on surface electromyography signal[J]. *Proceedings of the 2009 National Conference on Virtual Instrumentation (II)*, 2009
- [20] CAMPBELL E, PHINYOMARK A, SCHEME E. Deep Cross-User Models Reduce the Training Burden in Myoelectric Control[J]. *Frontiers in Neuroscience*, 2021, 15.
- [21] LUU D K, NGUYEN A T, JIANG M, et al. Deep learning-based approaches for decoding motor intent from peripheral nerve signals[J]. *Frontiers in Neuroscience*, 2021, 15: 667907.
- [22] ZHAI X, JELFS B, CHAN R H, et al. Self-recalibrating surface EMG pattern recognition for neuroprosthesis control based on convolutional neural network[J]. *Frontiers in neuroscience*, 2017, 11: 379.
- [23] SULTANA A, AHMED F, ALAM M S. A systematic review on surface electromyography-based classification system for identifying hand and finger movements[J]. *Healthcare Analytics*, 2022: 100126.
- [24] ATZORI M, GJISBERTS A, KUZBORSKI I, et al. Characterization of a benchmark database for myoelectric movement classification[J]. *IEEE transactions on neural systems and rehabilitation engineering*, 2014, 23(1): 73-83.
- [25] 付梦龙. 基于表面肌电信号的实时在线肌肉疲劳估计方法研究 [D]; 中国科学技术大学, 2020.
- FU M. Research on real-time online muscle fatigue estimation method based on surface electromyography[D]; University of Science and Technology of China, 2020.
- [26] ORTIZ-CATALAN M, BRANEMARK R, HAKANSSON B. BioPatRec: A modular research platform for the control of artificial limbs based on pattern recognition algorithms[J]. *Source Code Biol Med*, 2013, 8(1): 11.
- [27] FATIMAH B, SINGH P, SINGHAL A, et al. Hand movement recognition from sEMG signals using Fourier decomposition method[J]. *Biocybernetics and Biomedical Engineering*, 2021, 41(2): 690-703.
- [28] Amma C, Krings T, Böer J, et al. Advancing muscle-computer interfaces with high-density electromyography[C]// *Proceedings of the 33rd Annual ACM Conference on Human Factors in Computing Systems*. 2015: 929-938.
- [29] GENG W, DU Y, JIN W, et al. Gesture recognition by instantaneous surface EMG images [J]. *Sci Rep*, 2016, 6: 36571.
- [30] Dai Q, Li X, Geng W, et al. CAPG-MYO: a muscle-computer interface supporting user-defined gesture recognition[C]// *Proceedings of the 9th International Conference on Computer and Communications Management*. 2021: 52-58.
- [31] DU Y, JIN W, WEI W, et al. Surface EMG-based inter-session gesture recognition enhanced by deep domain adaptation [J]. *Sensors*, 2017, 17(3): 458.
- [32] 丁其川, 熊安斌, 赵新刚, 等. 基于表面肌电的运动意图识别方法研究及应用综述 [J]. *自动化学报*, 2016, 42(1): 13-25.
- DING Q, XIONG A, ZHAO X, et al. Research and application review of motion intention recognition method based on surface electromyography[J]. *Acta Automatica Sinica*, 2016, 42(1): 13-25.
- [33] KANG S, KIM H, PARK C, et al. sEMG-Based Hand

- Gesture Recognition Using Binarized Neural Network[J]. *Sensors*, 2023, 23(3): 1436.
- [34] 董泽萍 仇大伟, 刘静. 表面肌电人体下肢动作识别预测进展 [J]. *计算机工程与应用*, 2023.
- DONG Z, QIU D, LIU J. Advances in Human Lower Limb Action Recognition and Prediction by Surface Electromyography [J]. *Computer Engineering and Application*, 2023
- [35] CHOWDHURY R H, REAZ M B, ALI M A B M, et al. Surface electromyography signal processing and classification techniques [J]. *Sensors*, 2013, 13(9): 12431-66.
- [36] XUE J, SUN Z, DUAN F, et al. Underwater sEMG-based recognition of hand gestures using tensor decomposition[J]. *Pattern Recognition Letters*, 2023, 165: 39-46.
- [37] ZHANG Z, HE C, YANG K. A Novel Surface Electromyographic Signal-Based Hand Gesture Prediction Using a Recurrent Neural Network[J]. *Sensors (Basel)*, 2020, 20(14).
- [38] TEPE C, DEMIR M C. Real-Time Classification of EMG Myo Armband Data Using Support Vector Machine[J]. *Irbm*, 2022, 43(4): 300-8.
- [39] BAHADOR A, YOUSEFI M, MARASHI M, et al. High accurate lightweight deep learning method for gesture recognition based on surface electromyography[J]. *Computer Methods and Programs in Biomedicine*, 2020, 195: 105643.
- [40] PHINYOMARK A, PHUKPATTARANONT P, LIMSAKUL C. Feature reduction and selection for EMG signal classification[J]. *Expert systems with applications*, 2012, 39(8): 7420-31.
- [41] Ur Rehman M Z, Gilani S O, Waris A, et al. A novel approach for classification of hand movements using surface EMG signals[C]//2017 IEEE International Symposium on Signal Processing and Information Technology (ISSPIT). IEEE, 2017: 265-269.
- [42] ATZORI M, GIJSBERTS A, CASTELLINI C, et al. Electromyography data for non-invasive naturally-controlled robotic hand prostheses [J]. *Scientific data*, 2014, 1(1): 1-13.
- [43] NARAYAN Y. SEMG signal classification using KNN classifier with FD and TFD features [J]. *Materials Today: Proceedings*, 2021, 37: 3219-25.
- [44] AL-TIMEMY A H, BUGMANN G, ESCUDERO J, et al. Classification of finger movements for the dexterous hand prosthesis control with surface electromyography [J]. *IEEE journal of biomedical and health informatics*, 2013, 17(3): 608-18.
- [45] NOEMI GOZZI L M, FABIO MERCORIO, ALESSANDRA PEDROCCHI. XAI for myo-controlled prosthesis: Explaining EMG data for hand gesture classification[J]. *Knowledge-Based Systems*, 2022, Volume 240.
- [46] SHAO J, NIU Y, XUE C, et al. Single-channel SEMG using wavelet deep belief networks for upper limb motion recognition[J]. *International Journal of Industrial Ergonomics*, 2020, 76.
- [47] DUAN F, REN X, YANG Y. A Gesture Recognition System Based on Time Domain Features and Linear Discriminant Analysis[J]. *IEEE Transactions on Cognitive and Developmental Systems*, 2021, 13(1): 200-8.
- [48] NAIK G R, ACHARYYA A, NGUYEN H T. Classification of finger extension and flexion of EMG and Cyberglove data with modified ICA weight matrix[J]. *Annu Int Conf IEEE Eng Med Biol Soc*, 2014, 2014(USA,): 3829-32.
- [49] AL. M E B E. Real-time hand gesture recognition using the Myo armband and muscle activity detection[J]. 2017 IEEE Second Ecuador Technical Chapters Meeting (ETCM) , 2017: pp. 1-6.
- [50] BERGIL E, ORAL C, ERGUL E U. Efficient Hand Movement Detection Using k-Means Clustering and k-Nearest Neighbor Algorithms[J]. *Journal of Medical and Biological Engineering*, 2020, 41(1): 11-24.
- [51] CHEN X, WANG Z J. Pattern recognition of number gestures based on a wireless surface EMG system[J]. *Biomedical Signal Processing and Control*, 2013, 8(2): 184-92.
- [52] MALEKI A N A A. Artificial neural network classifier in comparison with LDA and LS-SVM classifiers to recognize 52 hand postures and movements [J]. 2014 4th International Conference on Computer and Knowledge Engineering (ICCKE), 2014.
- [53] 蔡芝蔚, 吴淑燕, 宋俊锋. 基于 SVM 和组合优化模型的手势识别 [J]. *系统仿真学报*, 2016, 28(8): 1812.
- CAI Z, WU S, SONG J. Gesture recognition based on SVM and combinatorial optimisation model[J]. *Journal of System Simulation*, 2016, 28(8): 1812.
- [54] 朱旭, 刘静, 董泽萍, 等. 基于表面肌电图手势动作意图识别的系统综述 [J]. *中国康复理论与实践*, 2022, 28(9): 1032-8.
- ZHU X, LIU J, DONG Z, et al. Systematic review of gesture action intention recognition based on surface electromyography[J]. *Chinese Rehabilitation Theory and Practice*, 2022, 28(9): 1032-8.
- [55] DING Z, YANG C, TIAN Z, et al. sEMG-Based Gesture Recognition with Convolution Neural Networks[J]. *Sustainability*, 2018, 10(6).
- [56] CHEN L, FU J, WU Y, et al. Hand gesture recognition using compact CNN via surface electromyography signals [J]. *Sensors*, 2020, 20(3): 672.
- [57] Côté-Allard U, Fall C L, Campeau-Lecours A, et al. Transfer learning for sEMG hand gestures recognition using convolutional neural networks[C]//2017 IEEE International Conference on Systems, Man, and Cybernetics (SMC). IEEE, 2017: 1663-1668.
- [58] TAM S, BOUKADOUM M, CAMPEAU-LECOURS A, et al. Intuitive real-time control strategy for high-density myoelectric hand prosthesis using deep and transfer learning [J]. *Scientific Reports*, 2021, 11(1): 11275.
- [59] QI S, WU X, CHEN W-H, et al. sEMG-based recognition of composite motion with convolutional neural network [J]. *Sensors and Actuators A: Physical*, 2020, 311.
- [60] Samadani A. Gated recurrent neural networks for EMG-based hand gesture classification. A comparative study[C]//2018 40th annual international conference of the IEEE Engineering in Medicine and Biology Society (EMBC). IEEE, 2018: 1-4.
- [61] SIMÃO M, NETO P, GIBARU O. EMG-based online classification of gestures with recurrent neural networks[J]. *Pattern Recognition Letters*, 2019, 128: 45-51.
- [62] WANG C, GUO W, ZHANG H, et al. sEMG-based continuous estimation of grasp movements by long-short term memory network[J]. *Biomedical Signal Processing and Control*, 2020, 59.
- [63] P. TSINGANOS B C, J. CORNELIS, B. JANSEN AND A. SKODRAS. Improved Gesture Recognition Based on sEMG Signals and TCN[J]. *ICASSP 2019 - 2019 IEEE International Conference on Acoustics*, 2019, Speech and Signal Processing (ICASSP),: pp. 1169-73.
- [64] BETTHAUSER J L, KRALL J T, BANNOWSKY S G, et

- al. Stable Responsive EMG Sequence Prediction and Adaptive Reinforcement With Temporal Convolutional Networks[J]. *IEEE Trans Biomed Eng*, 2020, 67(6): 1707-17.
- [65] J. L. BETTHAUSER J T K, R. R. KALIKI, M. S. FIFER AND N. V. THAKOR. Stable Electromyographic Sequence Prediction During Movement Transitions using Temporal Convolutional Networks[J]. 2019 9th International IEEE/EMBS Conference on Neural Engineering (NER), 2019, San Francisco(USA): pp. 1046-9.
- [66] M. ZANGHIERI S B, F. CONTI, A. BURRELLO AND L. BENINI. Temporal Variability Analysis in sEMG Hand Grasp Recognition using Temporal Convolutional Networks [J]. 2020 2nd IEEE International Conference on Artificial Intelligence Circuits and Systems (AICAS),, 2020: pp. 228-32.
- [67] ZANGHIERI M, BENATTI S, BURRELLO A, et al. Robust Real-Time Embedded EMG Recognition Framework Using Temporal Convolutional Networks on a Multicore IoT Processor [J]. *IEEE Trans Biomed Circuits Syst*, 2020, 14(2): 244-56.
- [68] COTE-ALLARD U, CAMPBELL E, PHINYOMARK A, et al. Interpreting Deep Learning Features for Myoelectric Control: A Comparison With Handcrafted Features [J]. *Front Bioeng Biotechnol*, 2020, 8: 158.
- [69] H. CHEN R T, M. CHEN, Y. FANG AND H. LIU A Hybrid Cnn-Svm Classifier For Hand Gesture Recognition With Surface Emg Signals[J]. 2018 International Conference on Machine Learning and Cybernetics (ICMLC), 2018: pp. 619-24.,
- [70] HU Y, WONG Y, WEI W, et al. A novel attention-based hybrid CNN-RNN architecture for sEMG-based gesture recognition [J]. *PLoS One*, 2018, 13(10): e0206049.
- [71] FARINA D, JIANG N, REHBAUM H, et al. The Extraction of Neural Information from the Surface EMG for the Control of Upper-Limb Prostheses: Emerging Avenues and Challenges [J]. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 2014, 22(4): 797-809.
- [72] OVUR S E, ZHOU X, QI W, et al. A novel autonomous learning framework to enhance sEMG-based hand gesture recognition using depth information [J]. *Biomedical Signal Processing and Control*, 2021, 66.
- [73] RAHIMIAN E, ZABIHI S, ASIF A, et al. TEMGNet: Deep transformer-based decoding of upperlimb sEMG for hand gestures recognition[J]. *arXiv preprint arXiv:210912379*, 2021.
- [74] McIntosh J, Marzo A, Fraser M, et al. Echoflex: Hand gesture recognition using ultrasound imaging[C]//*Pro- ceedings of the 2017 CHI Conference on Human Factors in Computing Systems*. 2017: 1923-1934.
- [75] YANG X, SUN X, ZHOU D, et al. Towards Wearable A-Mode Ultrasound Sensing for Real-Time Finger Motion Recognition [J]. *IEEE Trans Neural Syst Rehabil Eng*, 2018, 26(6): 1199-208.